

Tarea 3.

Instrucciones de entrega:

- Entregue un informe en formato **pdf** con sus resultados, pseudo código (si corresponde) y conclusiones. Además incluya su código en R o Python.
- Comente todas sus soluciones, y utilice herramientas gráficas, por ejemplo use el paquete **rgl** (u otro), si es que estima que esto le ayudará a presentar de mejor manera sus resultados.
- **Fecha de entrega:** 19 de Octubre
- Note que los puntos base de Tarea suman más que 6 puntos. En el caso de obtener más de 6 puntos, los puntos extras pueden ser utilizados en la Tarea 1 o en la Tarea 2.

Ejercicio 1 (Explorando kernels, 3 puntos). En este ejercicio el objetivo es explorar el comportamiento de diferentes kernels en la solución de kernel regression. Para esto considere la base de datos **starbucks** del paquete **openintro**, y considere la variable **carb** como variable respuesta y la variable **protein** como variable independiente. Para este ejercicio considere estandarización de la variable independiente y utilice toda la base de datos como set de entrenamiento.

1. Considere la función de **kernel constante** dada por:

$$K_c(x, y) = c, \quad c > 0$$

- a) Justifique que el kernel anterior es efectivamente un kernel (**Hint:** utilice las propiedades dadas en el capítulo de algebra de kernels).
- b) Utilice el kernel anterior para ajustar un modelo de regresión con kernels utilizando las variables descritas en el enunciado. Elija el parámetro c , de tal forma que se minimice el error cuadrático medio calculado en el set de entrenamiento (considere al menos 100 candidatos). Elija apropiadamente su parámetro de regularización λ .
- c) Grafique los valores ajustados obtenidos para su modelo.
- d) Repita los items a-c para los kernels dados por:
 - 1) kernel lineal

$$K_c(x, y) = 1 + c^2xy, \quad c > 0$$

- 2) kernel polinomial (grado 2)

$$K_c(x, y) = (c + xy)^2, \quad c > 0$$

- 3) kernel gaussiano

$$K_c(x, y) = \exp\{-(x - y)^2/c^2\}, \quad c > 0$$

Ejercicio 2 (Kernel Browniano). En este ejercicio nuestra inspiración es el **movimiento browniano**. El movimiento browniano es el movimiento aleatorio y descontrolado de una partícula, que se origina debido a constantes interacciones a escala microscópica con el ambiente. El movimiento browniano es muy importante en economía, física, y en la ciencia en general, ya que este movimiento se ha observado en una gran variedad de fenómenos, por ejemplo: en el movimiento de partículas de polen en el agua, en el modelamiento de portafolios en economía, en astronomía una estrella masiva puede experimentar el movimiento browniano debido a la interacción gravitacional con estrellas de menor tamaño, etc.

Sea X_t la posición de una partícula, que se mueve en los números reales a tiempo t . Si la partícula sigue una trayectoria browniana, entonces la covarianza entre las posiciones a tiempo t y s , es decir, X_t y X_s , está dada por $Cov(X_t, X_s) = K(t, s)$, donde la función $K : [0, \infty) \times [0, \infty) \rightarrow \mathbb{R}$ es:

$$K(t, s) = \sigma^2 \min\{t, s\},$$

que se conoce como el kernel browniano.

1. (2 puntos) La primera parte de este ejercicio, tiene como objetivo verificar que K es un kernel (usando la definición de kernel que aprendimos en clases, es decir, simétrico y semi-definido positivo).

- a) Sea $g : \mathbb{R}^d \times [0, \infty) \rightarrow \mathbb{R}$ una función que se evalúa en una covariable \mathbf{x} , y en un número real $t \in [0, \infty)$.

Defina $K : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ por

$$K(\mathbf{x}, \mathbf{x}') = \int_0^1 g(\mathbf{x}, t)g(\mathbf{x}', t)dt$$

Verifique que K es kernel: es decir que es simétrico y semi-definido positivo. **Hint:** para verificar que es semi-definido positivo use directamente la definición y manipule adecuadamente los términos.

- b) Muestre que $K(x, x') = \min(x, x')$ es un kernel, donde x y x' son números reales no-negativos.

Hint: Dados $b \geq 0$, defina la función $g_b : [0, \infty) \rightarrow \mathbb{R}$, tal que $g_b(t)$ que toma valor 1 si t está en el intervalo $[0, b]$, si no toma el valor 0. Use que $\int_0^\infty g_b(t)dt = b$. Combine con el ejercicio anterior.

- c) (Caso particular) Muestre que la función dada por $J : [0, 1) \times [0, 1) \rightarrow \mathbb{R}$ dado por

$$J(x, x') = \frac{1}{1 - \min(x, x')}$$

es un kernel.

Hint: recuerde la suma geométrica aprendida en su curso de cálculo.

2. (2 puntos) Considere los datos del archivo "datos.txt". Donde se encuentran muestras de $t \rightarrow f(t)$ para distintos valores de t . La primera columna contiene tiempos t y en la segunda contiene el valor $f(t)$.

- a) Utilice kernel regression (con parámetro de regularización $\lambda = 0,01$), usando el kernel Squared-exponential

$$K_1(\mathbf{x}, \mathbf{x}') = \exp(-(\mathbf{x} - \mathbf{x}')^2 / \ell^2)$$

y usando el kernel browniano

$$K_2(\mathbf{x}, \mathbf{x}') = \sigma^2 \min(\mathbf{x}, \mathbf{x}').$$

Encuentre parámetros σ^2 y ℓ^2 de tal forma que, en ambos casos, el **error cuadrático medio** calculado en el set de entreamiento sea del orden de 10^{-6} , es decir, su error debe ser del tipo 0,00000x, es decir, 5 ceros antes de su primera cifra significativa.

Ojo 1: Se pide calcular el error cuadrático medio, **no** el error cuadrático medio predictivo, así que use todas las observaciones que consideró en el set de entrenamiento para calcularlo.

Ojo 2: Note que en este ejercicio **no se pide hacer cross-validation**, así que puede usar toda la base de datos como set de entrenamiento.

- b) Grafique los mapas de calor de los kernels K_1 y K_2 con los parámetros encontrados y algunas funciones asociadas al RKHS ¿Qué opina sobre los resultados? ¿Qué kernel le parece más confiable para este problema?